

PROJETO INTEGRADOR UC 10

Previsão de Desempenho Acadêmico com Machine Learning

Napoleão Júnior, Tainara Almeida, Júlia Stefany

Ciência de Dados • 2026

Da rotina de estudos à previsão

O PROBLEMA

Como prever o desempenho acadêmico de estudantes com base em hábitos de estudo e estilo de vida? A identificação precoce de alunos em risco permite **intervenções pedagógicas direcionadas**.

O OBJETIVO

Desenvolver um pipeline de Machine Learning para classificar estudantes nas categorias **A, B, C, D ou F**, avaliando a influência de variáveis socioeconômicas e comportamentais na nota final.

Propósito e base técnica

1. Objetivo principal

- Identificar as escolaridades mais afetadas no desempenho
- Analisar cotidiano que possa afetar os estudos
- Diferença entre gênero nos estudos

2. Tecnologías utilizadas

Desenvolvido com Python, Pandas, NumPy, imbalanced-learn, Matplotlib, Seaborn, Power Bi, github

3. Fonte de dados

Kaggle:
<https://www.kaggle.com/datasets/harshadapatil31/student-performance-and-study-habits-dataset>

O que os dados contam

1.000

AMOSTRAS

09

FEATURES

05

CLASSES

Variáveis de Entrada

Gênero

Horas de Estudo

Percentual de Frequência

Horas de Sono

Nota Anterior

Escolaridade dos Pais

Acesso à Internet

Atividades Extracurriculares

Trabalho de Meio Período

Fonte: Student Performance & Study Habits Dataset (Kaggle)

Um pipeline ponta a ponta

01

Aquisição

Carga do dataset original e inspeção inicial.

02

Tradução

Renomeação de colunas e valores para PT-BR.

03

Limpeza

Remoção de duplicados e dados omissos.

04

Tratamento

Conversão de categorias para numéricas.

05

Split 70/30

Divisão estratificada entre treino e teste.

06

SMOTE

Balanceamento de classes apenas no treino.

07

Padronização

StandardScaler para normalizar escalas.

08

PCA

Redução de dimensionalidade (2 a 5 comp).

09

Treinamento

KNN (k=3,5,7) e Random Forest.

10

Avaliação

F1-macro e Matriz de Confusão.

1

Tradução dos dados

```
import pandas as pd

# Carregar o arquivo traduzido
df = pd.read_csv(
    r"desempenho_estudantil\traducao_dados.csv"
)

# Exibir as primeiras linhas
print("Dados originais:")
print(df.head())

# Converter variáveis categóricas para binárias/numéricas
df["genero"] = df["genero"].replace({
    "Masculino": 1,
    "Feminino": 0
})

df["escolaridade_pais"] = df["escolaridade_pais"].replace({
    "Ensino Médio": 1,
    "Bacharelado": 2,
    "Mestrado": 3,
    "Doutorado": 4
})

df["acesso_internet"] = df["acesso_internet"].replace({
    "Sim": 1,
    "Não": 0
})

df["atividades_extracurriculares"] = df["atividades_extracurriculares"].replace({
    "Sim": 1,
    "Não": 0
})

df["trabalho_meio_periodo"] = df["trabalho_meio_periodo"].replace({
    "Sim": 1,
    "Não": 0
})

df = df.replace(r'^\s*$', None, regex=True)
print(df.isnull().sum())

# -----
# Binarizar a nota final: A, B, C = Aprovado (1) | D, F = Reprovado (0)
# -----
mapa_nota = {"A": 1, "B": 1, "C": 1, "D": 0, "F": 0}
df["nota_final"] = df["nota_final"].map(mapa_nota)
```

Resultado

```
/julia59708906/Documents/UC10_PF_MACHINE_LEARNING/traducao_dados.py
id_estudante      0
genero             0
horas_estudo       0
percentual_frequencia 0
horas_sono         0
escolaridade_pais 102
acesso_internet    0
atividades_extracurriculares 0
trabalho_meio_periodo 0
nota_anterior      0
pontuacao_prova_final 0
nota_final         0
dtype: int64
Arquivo traduzido com sucesso!

   id_estudante  genero  horas_estudo  percentual_frequencia  ...  trabalho_meio_periodo  nota_anterior  pontuacao_prova_final  nota_final
0              1  Masculino         4.0                98.0  ...                   Não          76.9              100.0          A
1              2  Feminino         6.3                100.0  ...                   Sim          75.5              100.0          A
2              3  Masculino         4.9                85.3  ...                   Sim          88.5               97.3          A
3              4  Masculino         2.6                77.5  ...                   Não          85.1               83.8          B
4              5  Masculino         2.2                89.6  ...                   Sim          61.8               68.3          D

[5 rows x 12 columns]
(venv) PS C:\Users\julia59708906\Documents\UC10_PF_MACHINE_LEARNING>
```

```

$ tratados.py  tratamento_dados_binario.csv X
es > julia5970006 > Downloads > trabalho do curso > UC10_PFE_MACHINE_LEARNING > desempenho_estudantil > tratamento_dados_binario.csv > data
id,estudante,genero,horas_estudo,percentual_frequencia,horas_sono,escolaridade_pais,acesso_internet,atividades_extracurriculares,trabalho_meio_periodo,nota_anterior,pontuacao_prova_final,nota_final
1,1,4,0,88,0,6,5,2,1,1,0,78,9,100,0,1
2,0,6,3,100,0,5,7,1,1,1,1,75,5,100,0,1
3,1,4,9,85,1,7,9,2,1,0,1,80,5,97,3,1
4,1,2,6,77,5,8,0,0,1,1,0,85,1,83,0,1
5,1,2,2,89,6,4,6,2,1,0,1,81,0,68,2,0
6,0,4,2,70,2,5,7,1,1,0,0,79,0,81,6,1
7,1,1,5,100,0,5,0,1,1,1,1,58,6,69,6,0
8,1,6,2,86,4,6,0,1,1,1,0,78,4,88,0,1
9,1,5,3,81,1,6,7,2,1,0,0,83,0,84,4,1
10,0,2,0,88,0,5,1,2,1,1,0,57,7,74,3,1
11,1,0,9,71,5,5,7,1,1,0,1,73,4,68,9,0
12,1,5,5,75,3,5,6,0,1,1,0,57,0,76,7,1
13,1,3,3,97,0,7,0,3,1,1,1,69,0,82,6,1
14,1,5,4,70,4,6,9,2,0,0,0,67,9,93,3,1
15,0,1,1,74,5,5,9,3,1,1,1,71,0,73,9,1
16,1,2,6,90,4,7,0,1,1,1,0,85,0,84,0,1
17,0,3,5,90,9,6,4,2,1,1,0,51,0,81,5,1
18,0,3,6,92,2,6,5,2,1,1,1,68,2,75,5,1
19,0,2,0,95,0,8,0,3,0,1,0,74,7,69,7,1
20,1,4,4,77,4,8,4,3,0,0,1,77,0,92,0,1
21,0,1,9,70,0,5,2,1,1,1,1,60,0,73,5,1
22,1,3,3,100,0,7,8,0,1,1,0,83,7,100,0,1
23,0,3,7,81,0,7,8,1,0,0,0,74,0,73,4,1
24,0,4,3,82,5,5,4,4,0,1,0,61,0,71,2,1
25,0,4,6,98,3,7,8,0,1,1,1,66,0,97,2,1
26,0,1,0,90,6,8,6,1,1,0,0,53,2,76,0,1
27,0,1,2,89,6,5,5,3,1,0,1,68,7,78,7,1
28,0,5,4,100,0,5,7,1,0,0,0,81,1,97,4,1
29,0,4,0,78,6,8,0,2,1,0,0,78,2,84,2,1
30,0,2,4,94,3,7,1,2,1,1,0,80,0,89,0,1
31,1,5,8,85,6,7,5,2,1,0,1,68,4,82,4,1
32,1,3,7,87,7,7,2,0,1,1,0,80,2,87,7,1
33,0,5,3,100,0,7,3,3,1,1,0,67,7,100,0,1
34,0,3,6,90,1,5,2,2,0,1,0,87,7,93,3,1
35,0,6,6,90,4,8,1,3,1,1,1,69,7,100,0,1
36,1,6,1,95,7,8,2,0,1,1,1,70,5,92,9,1
37,0,3,1,81,4,6,5,1,1,0,1,87,7,83,2,1

```

```

desempenho_estudantil
├── student_performance_dataset.csv
├── traducao_dados.csv
├── traducao_dados.pdf
├── tratamento_dados_binario_inicio.csv
├── tratamento_dados_binario.csv
├── tratamento_dados_binario.pdf
├── graficos
├── reports
├── venv
├── .gitignore
├── aprendizado_inicio.py
├── aprendizado_machine.py
├── dados_tratados.py
├── README.md
├── requirements.txt
├── traducao_dados.csv
└── traducao_dos_dados.py

```

3

Tratamento dos dados

```
import pandas as pd

# Carregar o arquivo traduzido
df = pd.read_csv(
    r"desempenho_estudantil\traducao_dados.csv"
)

# Exibir as primeiras linhas
print("Dados originais:")
print(df.head())

# Converter variáveis categóricas para binárias/numéricas
df["genero"] = df["genero"].replace({
    "Masculino": 1,
    "Feminino": 0
})

df["escolaridade_pais"] = df["escolaridade_pais"].replace({
    "Ensino Médio": 1,
    "Bacharelado": 2,
    "Mestrado": 3,
    "Doutorado": 4
})

df["acesso_internet"] = df["acesso_internet"].replace({
    "Sim": 1,
    "Não": 0
})

df["atividades_extracurriculares"] = df["atividades_extracurriculares"].replace({
    "Sim": 1,
    "Não": 0
})
```

2

Resultado

Dados originais:

	id_estudante	genero	horas_estudo	percentual_frequencia	...	trabalho_meio_periodo	nota_anterior	pontuacao_prova_final	nota_final
0	1	Masculino	4.0	98.0	...	Não	76.9	100.0	A
1	2	Feminino	6.3	100.0	...	Sim	75.5	100.0	A
2	3	Masculino	4.9	85.3	...	Sim	88.5	97.3	A
3	4	Masculino	2.6	77.5	...	Não	85.1	83.8	B
4	5	Masculino	2.2	89.6	...	Sim	61.8	68.3	D

[5 rows x 12 columns]

```
id_estudante      0
genero            0
horas_estudo      0
percentual_frequencia 0
horas_sono        0
escolaridade_pais 102
acesso_internet   0
atividades_extracurriculares 0
trabalho_meio_periodo 0
nota_anterior     0
pontuacao_prova_final 0
nota_final        0
dtype: int64
```

Distribuição de 'nota_final' APÓS binarização:

```
nota_final
B    354
A    284
C    261
D     89
F     12
Name: count, dtype: int64
Valores únicos: ['A', 'B', 'C', 'D', 'F']
```

Arquivo tratado com sucesso!

Primeiras linhas após a conversão:

	id_estudante	genero	horas_estudo	percentual_frequencia	...	trabalho_meio_periodo	nota_anterior	pontuacao_prova_final	nota_final
0	1	1	4.0	98.0	...	0	76.9	100.0	A
1	2	0	6.3	100.0	...	1	75.5	100.0	A
2	3	1	4.9	85.3	...	1	88.5	97.3	A
3	4	1	2.6	77.5	...	0	85.1	83.8	B
4	5	1	2.2	89.6	...	1	61.8	68.3	D

[5 rows x 12 columns]

(venv) PS C:\Users\julia59780906\Documents\UC10_PF_MACHINE_LEARNING>


```
"""
```

```
PI - UC 10 | Aprendizado de Máquina
```

```
Classificação MULTICLASSE: A, B, C, D, F
```

```
Pipeline (segue as orientações do professor):
```

```
Aquisição -> Limpeza/Tratamento -> Balanceamento (SMOTE, só no treino)
```

```
-> Split 70/30 estratificado -> StandardScaler -> PCA (2,3,4,5)
```

```
-> KNN (k = 3, 5, 7) + Random Forest -> Avaliação (Acc/Prec/Rec/F1)
```

```
-> Matriz de Confusão -> Melhor modelo (F1-macro) -> Previsão
```

```
"""
```

```
import os
import warnings
warnings.filterwarnings("ignore")
```

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.neighbors import KNeighborsClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import (accuracy_score, precision_score, recall_score,
                             f1_score, confusion_matrix, classification_report)
```

```
# SMOTE é opcional (se não tiver, o código segue com class_weight)
```

```
try:
    from imblearn.over_sampling import SMOTE
    IMBLEARN_OK = True
except ImportError:
    IMBLEARN_OK = False
```

```
(venv) PS C:\Users\julia59700906\Documents\trabalho do curso\UC10_PF_MACHINE_LEARNING> &"c:\Users\julia59700906\Documents\trabalho do curso\UC10_PF_MACHINE_LEARNING\Scripts\python.exe" "c:\Users\julia59700906\Documents\trabalho do curso\UC10_PF_MACHINE_LEARNING\aprendizado_machine.py"
```

```
[1] Dataset carregado: 1000 linhas x 12 colunas
```

id_estudante	genero	horas_estudo	percentual_frequencia	trabalho_meio_periodo	nota_anterior	pontuacao_prova_final	nota_final
0	1	1	4.0	98.0 ...	0	76.9	100.0
1	2	0	6.3	100.0 ...	1	75.5	100.0
2	3	1	4.9	85.3 ...	1	88.5	97.3
3	4	1	2.6	77.5 ...	0	85.1	83.8
4	5	1	2.2	89.6 ...	1	61.8	68.3

```
[5 rows x 12 columns]
```

```
[2.1] Duplicados removidos: 0
```

```
[2.2] Linhas com dados omissos removidas: 0
```

```
Distribuição original das classes:
```

```
nota_final
A    284
B    354
C    261
D     89
F     12
Name: count, dtype: int64
```

```
[4] Treino: (700, 9) | Teste: (300, 9)
```

```
[5] SMOTE aplicado APENAS no treino (k_neighbors=5).
```

```
Distribuição pós-balanceamento (treino):
```

```
nota_final
A    248
B    248
C    248
D    248
F    248
Name: count, dtype: int64
```

```
[6] StandardScaler ajustado no treino e aplicado no teste.
```

```
[7.3] Resultados parciais (KNN):
```


pca	var_explicada	k	acuracia	precision	recall	f1_macro
2	0.3134	7	0.5033	0.4381	0.4872	0.4490
2	0.3134	5	0.4700	0.3985	0.4540	0.4109
2	0.3134	3	0.4367	0.3835	0.4288	0.3953
3	0.4309	7	0.4500	0.3710	0.4164	0.3821
4	0.5465	7	0.4733	0.3734	0.4022	0.3819
5	0.6494	3	0.4833	0.3768	0.3772	0.3739
3	0.4309	5	0.4300	0.3561	0.3845	0.3641
4	0.5465	3	0.4400	0.3527	0.3772	0.3565
3	0.4309	3	0.4000	0.3463	0.3752	0.3500
4	0.5465	5	0.4300	0.3431	0.3611	0.3472
5	0.6494	5	0.4300	0.3362	0.3450	0.3381
5	0.6494	7	0.4167	0.3190	0.3271	0.3210

```
[7.4] Resultados finais (KNN + Random Forest):
```

pca	var_explicada	k	acuracia	precision	recall	f1_macro
4	0.5465	RF	0.5100	0.4537	0.5125	0.4736
5	0.6494	RF	0.5267	0.4586	0.4717	0.4635
2	0.3134	7	0.5033	0.4381	0.4872	0.4490
3	0.4309	RF	0.4633	0.4053	0.4705	0.4251
2	0.3134	5	0.4700	0.3985	0.4540	0.4109
2	0.3134	3	0.4367	0.3835	0.4288	0.3953
3	0.4309	7	0.4500	0.3710	0.4164	0.3821
4	0.5465	7	0.4733	0.3734	0.4022	0.3819
5	0.6494	3	0.4833	0.3768	0.3772	0.3739
2	0.3134	RF	0.4400	0.3669	0.4023	0.3712
3	0.4309	5	0.4300	0.3561	0.3845	0.3641
4	0.5465	3	0.4400	0.3527	0.3772	0.3565
3	0.4309	3	0.4000	0.3463	0.3752	0.3500
4	0.5465	5	0.4300	0.3431	0.3611	0.3472
5	0.6494	5	0.4300	0.3362	0.3450	0.3381
5	0.6494	7	0.4167	0.3190	0.3271	0.3210

Comparação por gênero

Comparação da prova final por gênero



Diferença absoluta

- Masculino: 259 estudantes
- Feminino: 256 estudantes


Diferença de apenas 3
estudantes.

Diferença percentual

- Masculino: 50,29%
- Feminino: 49,71%

Diferença de apenas 0,58 ponto
percentual.


Impacto do Trabalho em Meio Período na Frequência Escolar por Gênero




Há **17 mulheres** a mais
trabalhando em meio período
do que homens.

Há apenas **5 homens** a mais
que mulheres entre os
estudantes que não exercem
atividade de meio período

Equilibrar para aprender melhor




ORIGINAL (DESBALANCEADO)



SMOTE (EQUALIZADO NO TREINO)

O SMOTE permite que o modelo aprenda as características de todas as notas (A-F) igualmente, evitando o viés em favor das classes majoritárias.

Reduzir dimensão sem perder o sinal



Variância Explicada

O PCA foi testado com diferentes números de componentes para otimizar o compromisso entre compressão e informação.

02 Componentes	31,34%
03 Componentes	43,09%
04 Componentes	54,65%
05 Componentes	64,94%

Conclusão PCA


4 componentes foram suficientes para capturar a maior parte da tendência central sem ruído excessivo.

16 combinações, uma escolha

PCA	CLASSIFICADOR	ACURÁCIA	PRECISÃO	RECALL	F1-MACRO
4	Random Forest	51,00%	0,4537	0,5125	0,4736
5	Random Forest	52,67%	0,4586	0,4717	0,4635
2	KNN (k=7)	50,33%	0,4381	0,4872	0,4490
3	Random Forest	46,33%	0,4053	0,4705	0,4251
2	KNN (k=5)	47,00%	0,3985	0,4540	0,4109

*Modelos ordenados pelo F1-Macro, métrica escolhida devido ao desbalanceamento das classes.


Random Forest leva vantagem



O **Random Forest** superou o KNN em quase todos os cenários de PCA, demonstrando maior robustez para lidar com a complexidade das 5 classes.

Apesar da superioridade, o desempenho geral próximo a 50% revela que a classificação de notas finas (A, B, C, D, F) é altamente desafiadora.

O que o melhor modelo aprendeu



Matriz de Confusão: Random Forest com PCA 4

51,0%

ACURÁCIA

0,4736

F1-MACRO

Previsão para Novo Estudante

Entrada: Masculino, 4.5h estudo, 90% freq, 7h sono, Pais Doutorado, Internet: Sim, Extracurriculares: Sim, Trabalho: Não, Nota Anterior: 20.

Classificação do Modelo: C

O modelo tende a confundir classes adjacentes (como B e C), indicando sobreposição de comportamentos entre diferentes níveis de notas.

Repositório:


https://github.com/NapoleaoJunior/UC10_PE_MACHINE_LEARNING

Relatório:

https://docs.google.com/document/d/1Fn1f0STOWUuf6I2oSITAxSvL6rS_z-3B/edit?usp=sharing&ouid=107562332198605647163&rtpof=true&sd=true

Kaggle:

<https://www.kaggle.com/datasets/harshadapatil31/student-performance-and-study-habits-dataset>



Até a próxima!

NAPOLEÃO • TAINARA • JÚLIA