

“

PREVENDO O DESEMPENHO ACADÊMICO DOS ESTUDANTES

”

Projeto Integrador — UC 10 | Ciência de Dados | 30 setembro

INTRODUÇÃO



Muitos estudantes enfrentam dificuldades para acompanhar o ritmo acadêmico, correndo o risco de reprovação. Nosso projeto utiliza Machine Learning para identificar precocemente os alunos em potencial risco, com base em desempenho acadêmico influenciado por diversos fatores, como hábitos de estudo, frequência às aulas, horas de sono, o gênero do estudante entre outros aspectos relacionados ao estilo de vida.

Utilizamos técnicas de aprendizado de máquina para prever e analisar o desempenho acadêmico de estudantes, classificando-os em duas categorias: Aprovado ou Reprovado, com base em dados e porcentagem. Assim, podemos intervir e oferecer suporte antes que seja tarde demais.

PROPÓSITO E BASE TÉCNICA

01. OBJETIVO PRINCIPAL

- Identificar as escolaridades mais afetadas no desempenho
- Analisar cotidiano que possa afetar os estudos
- Diferença entre gênero nos estudos

02. TECNOLOGIAS UTILIZADAS

Desenvolvido com Python, Pandas, NumPy, imbalanced-learn, Matplotlib, Seaborn, Power Bi, github

03. FONTE DOS DADOS

Kaggle:

<https://www.kaggle.com/datasets/harshadapatil31/student-performance-and-study-habits-dataset>

TRATAMENTO DOS DADOS

01. Tradução dos dados

```
import pandas as pd

# Carregar o arquivo traduzido
df = pd.read_csv(
    r"desempenho_estudantil\traducao_dados.csv"
)

# Exibir as primeiras linhas
print("Dados originais:")
print(df.head())

# Converter variáveis categóricas para binárias/numéricas
df["genero"] = df["genero"].replace({
    "Masculino": 1,
    "Feminino": 0
})

df["escolaridade_pais"] = df["escolaridade_pais"].replace({
    "Ensino Médio": 1,
    "Bacharelado": 2,
    "Mestrado": 3,
    "Doutorado": 4
})

df["acesso_internet"] = df["acesso_internet"].replace({
    "Sim": 1,
    "Não": 0
})

df["atividades_extracurriculares"] = df["atividades_extracurriculares"].replace({
    "Sim": 1,
    "Não": 0
})

df["trabalho_meio_periodo"] = df["trabalho_meio_periodo"].replace({
    "Sim": 1,
    "Não": 0
})

df = df.replace(r'^\s*$', None, regex=True)
print(df.isnull().sum())

# -----
# Binarizar a nota final: A, B, C = Aprovado (1) | D, F = Reprovado (0)
# -----
mapa_nota = {"A": 1, "B": 1, "C": 1, "D": 0, "F": 0}
df["nota_final"] = df["nota_final"].map(mapa_nota)
```

02. Resultado

```
/julia59700906/Documents/UC10_PF_MACHINE_LEARNING/traducao_dos_dados.py
id_estudante      0
genero             0
horas_estudo       0
percentual_frequencia 0
horas_sono         0
escolaridade_pais 102
acesso_internet    0
atividades_extracurriculares 0
trabalho_meio_periodo 0
nota_anterior      0
pontuacao_prova_final 0
nota_final         0
dtype: int64
Arquivo traduzido com sucesso!
   id_estudante  genero  horas_estudo  percentual_frequencia  ...  trabalho_meio_periodo  nota_anterior  pontuacao_prova_final  nota_final
0              1  Masculino          4.0                98.0  ...                Não           76.9                100.0            A
1              2  Feminino          6.3               100.0  ...                Sim           75.5                100.0            A
2              3  Masculino          4.9                85.3  ...                Sim           88.5                 97.3            A
3              4  Masculino          2.6                77.5  ...                Não           85.1                 83.8            B
4              5  Masculino          2.2                89.6  ...                Sim           61.8                 68.3            D

[5 rows x 12 columns]
(venv) PS C:\Users\julia59700906\Documents\UC10_PF_MACHINE_LEARNING>
```

TRATAMENTO DOS DADOS

01. Dados binario

```
s_tratados.py  tratamento_dados_binario.csv X
rs > julia59700906 > Downloads > trabalho do curso > UC10_PF_MACHINE_LEARNING > desempenho_estudantil > tratamento_dados_binario.csv > data
id_estudante,genero,horas_estudo,percentual_frequencia,horas_sono,escolaridade_pais,acesso_internet,atividades_extracurriculares,trabalho_meio_periodo,nota_anterior,pontuacao_prova_final,nota_final
1,1,4.0,98.0,6.5,2,1,1,0,76.9,100.0,1
2,0,6.3,100.0,5.7,1,1,1,1,75.5,100.0,1
3,1,4.9,85.3,7.9,2,1,0,1,88.5,97.3,1
4,1,2.6,77.5,8.0,0,1,1,0,85.1,83.8,1
5,1,2.2,89.6,4.6,2,1,0,1,61.8,68.3,0
6,0,4.2,78.2,5.7,1,1,0,0,79.8,81.6,1
7,1,1.5,100.0,5.0,1,1,1,1,58.6,69.6,0
8,1,6.2,86.4,6.0,1,1,1,0,78.4,88.0,1
9,1,5.3,81.3,6.7,2,1,0,0,63.8,84.4,1
10,0,2.8,86.8,5.1,2,1,1,0,57.7,74.3,1
11,1,0.9,71.5,5.7,1,1,0,1,73.4,68.9,0
12,1,5.5,75.3,5.6,0,1,1,0,37.9,76.7,1
13,1,3.3,97.0,7.0,3,1,1,1,49.0,82.6,1
14,1,5.4,78.4,6.9,2,0,0,0,67.9,93.3,1
15,0,1.1,74.5,5.9,3,1,1,1,71.0,73.9,1
16,1,2.6,90.4,7.0,1,1,1,0,65.6,84.8,1
17,0,3.5,96.9,6.1,2,1,1,0,51.0,81.5,1
18,0,3.6,92.2,6.5,2,1,1,1,60.2,75.5,1
19,0,2.8,95.0,8.8,3,0,1,0,74.7,89.7,1
20,1,4.4,77.4,8.4,3,0,0,1,77.0,92.8,1
21,0,1.9,70.8,5.2,1,1,1,0,69.8,73.5,1
22,1,3.3,100.0,7.8,0,1,1,0,83.9,100.0,1
23,0,3.7,81.8,7.8,1,0,0,0,74.8,73.4,1
24,0,4.3,82.5,5.4,4,0,1,0,61.0,71.2,1
25,0,4.6,98.3,7.8,0,1,1,1,66.6,97.2,1
26,0,1.8,90.6,8.6,1,1,0,0,53.2,76.0,1
27,0,1.2,89.6,5.5,3,1,0,1,68.7,78.7,1
28,0,5.4,100.0,5.7,1,0,0,0,83.3,97.4,1
29,0,4.0,78.6,8.0,2,1,0,0,78.2,84.2,1
30,0,2.4,94.3,7.1,2,1,1,0,86.8,89.8,1
31,1,5.8,85.6,7.5,2,1,0,1,66.4,82.4,1
32,1,3.7,87.7,7.2,0,1,1,0,86.2,87.7,1
33,0,5.3,100.0,7.3,3,1,1,0,67.7,100.0,1
34,0,3.6,90.1,5.2,2,0,1,0,87.7,93.3,1
35,0,6.6,90.4,8.1,3,1,1,1,69.7,100.0,1
36,1,6.1,95.7,8.2,0,1,1,1,78.5,92.9,1
37,0,3.1,81.4,6.5,1,1,0,1,87.7,83.2,1
```

02. Load

```
desempenho_estudantil
├── student_performance_dataset.csv
├── traducao_dados.csv
├── traducao_dados.pdf
├── tratamento_dados_binario_inicio.csv
├── tratamento_dados_binario.csv
├── tratamento_dados_binario.pdf
├── graficos
├── reports
├── venv
├── .gitignore
├── aprendizado_inicio.py
├── aprendizado_machine.py
├── dados_tratados.py
├── README.md
├── requirements.txt
├── traducao_dados.csv
├── traducao_dos_dados.py
```

TRATAMENTO DOS DADOS

01. Dados tratados

```
import pandas as pd

# Carregar o arquivo traduzido
df = pd.read_csv(
    r"desempenho_estudantil\traducao_dados.csv"
)

# Exibir as primeiras linhas
print("Dados originais:")
print(df.head())

# Converter variáveis categóricas para binárias/numéricas
df["genero"] = df["genero"].replace({
    "Masculino": 1,
    "Feminino": 0
})

df["escolaridade_pais"] = df["escolaridade_pais"].replace({
    "Ensino Médio": 1,
    "Bacharelado": 2,
    "Mestrado": 3,
    "Doutorado": 4
})

df["acesso_internet"] = df["acesso_internet"].replace({
    "Sim": 1,
    "Não": 0
})

df["atividades_extracurriculares"] = df["atividades_extracurriculares"].replace({
    "Sim": 1,
    "Não": 0
})
```

02. Resultado

```
Dados originais:
id_estudante  genero  horas_estudo  percentual_frequencia  ...  trabalho_meio_periodo  nota_anterior  pontuacao_prova_final  nota_final
0            1  Masculino         4.0             98.0  ...              Não          76.9             100.0           A
1            2  Feminino         6.3             100.0  ...              Sim           75.5             100.0           A
2            3  Masculino         4.9             85.3  ...              Sim           88.5              97.3           A
3            4  Masculino         2.6             77.5  ...              Não           85.1              83.8           B
4            5  Masculino         2.2             89.6  ...              Sim           61.8              68.3           D

[5 rows x 12 columns]
id_estudante      0
genero             0
horas_estudo      0
percentual_frequencia  0
horas_sono        0
escolaridade_pais  102
acesso_internet    0
atividades_extracurriculares  0
trabalho_meio_periodo  0
nota_anterior      0
pontuacao_prova_final  0
nota_final         0
dtype: int64

Distribuição de 'nota_final' APÓS binarização:
nota_final
B    354
A    284
C    261
D     89
F     12
Name: count, dtype: int64
Valores únicos: ['A', 'B', 'C', 'D', 'F']

Arquivo tratado com sucesso!

Primeiras linhas após a conversão:
id_estudante  genero  horas_estudo  percentual_frequencia  ...  trabalho_meio_periodo  nota_anterior  pontuacao_prova_final  nota_final
0            1      1         4.0             98.0  ...              0          76.9             100.0           A
1            2      0         6.3             100.0  ...              1          75.5             100.0           A
2            3      1         4.9             85.3  ...              1          88.5              97.3           A
3            4      1         2.6             77.5  ...              0          85.1              83.8           B
4            5      1         2.2             89.6  ...              1          61.8              68.3           D

[5 rows x 12 columns]
(venv) PS C:\Users\julia59700906\Documents\UC10_PF_MACHINE_LEARNING>
```

01. Aprendizado_Machine

```
"""
PI - UC 10 | Aprendizado de Máquina
Classificação MULTICLASSE: A, B, C, D, F

Pipeline (segue as orientações do professor):
  Aquisição -> Limpeza/Tratamento -> Balanceamento (SMOTE, só no treino)
  -> Split 70/30 estratificado -> StandardScaler -> PCA (2,3,4,5)
  -> KNN (k = 3, 5, 7) + Random Forest -> Avaliação (Acc/Prec/Rec/F1)
  -> Matriz de Confusão -> Melhor modelo (F1-macro) -> Previsão
"""

import os
import warnings
warnings.filterwarnings("ignore")

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.neighbors import KNeighborsClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import (accuracy_score, precision_score, recall_score,
                              f1_score, confusion_matrix, classification_report)

# SMOTE é opcional (se não tiver, o código segue com class_weight)
try:
    from imblearn.over_sampling import SMOTE
    IMBLEARN_OK = True
except ImportError:
    IMBLEARN_OK = False
```

02. Resultado

```
(venv) PS C:\Users\julia59700906\Documents\trabalho do curso\UC10_PF_MACHINE_LEARNING> & "c:\Users\julia59700906\Documents\trabalho do curso\UC10_PF_MACHINE_LEARNING\venv\Scripts\python.exe" "c:/Users/julia59700906/Documents/trabalho do curso/UC10_PF_MACHINE_LEARNING/aprendizado_machine.py"
[1] Dataset carregado: 1000 linhas x 12 colunas
   id_estudante  genero  horas_estudo  percentual_frequencia  ...  trabalho_meio_periodo  nota_anterior  pontuacao_prova_final  nota_final
0             1       1           4.0             98.0  ...                0             76.9             100.0             A
1             2       0           6.3             100.0  ...                1             75.5             100.0             A
2             3       1           4.9             85.3  ...                1             88.5              97.3             A
3             4       1           2.6             77.5  ...                0             85.1              83.8             B
4             5       1           2.2             89.6  ...                1             61.8              68.3             D
[5 rows x 12 columns]

[2.1] Duplicados removidos: 0
[2.2] Linhas com dados omissos removidas: 0

Distribuição original das classes:
nota_final
A      284
B      354
C      261
D       89
F       12
Name: count, dtype: int64

[4] Treino: (700, 9) | Teste: (300, 9)
[5] SMOTE aplicado APENAS no treino (k_neighbors=5).
Distribuição pós-balanceamento (treino):
nota_final
A      248
B      248
C      248
D      248
F      248
Name: count, dtype: int64
```

[6] StandardScaler ajustado no treino e aplicado no teste.

[7.3] Resultados parciais (KNN):


pca	var_explicada	k	acuracia	precision	recall	f1_macro
2	0.3134	7	0.5033	0.4381	0.4872	0.4490
2	0.3134	5	0.4700	0.3985	0.4540	0.4109
2	0.3134	3	0.4367	0.3835	0.4288	0.3953
3	0.4309	7	0.4500	0.3710	0.4164	0.3821
4	0.5465	7	0.4733	0.3734	0.4022	0.3819
5	0.6494	3	0.4833	0.3768	0.3772	0.3739
3	0.4309	5	0.4300	0.3561	0.3845	0.3641
4	0.5465	3	0.4400	0.3527	0.3772	0.3565
3	0.4309	3	0.4000	0.3463	0.3752	0.3500
4	0.5465	5	0.4300	0.3431	0.3611	0.3472
5	0.6494	5	0.4300	0.3362	0.3450	0.3381
5	0.6494	7	0.4167	0.3190	0.3271	0.3210

[7.4] Resultados finais (KNN + Random Forest):

pca	var_explicada	k	acuracia	precision	recall	f1_macro
4	0.5465	RF	0.5100	0.4537	0.5125	0.4736
5	0.6494	RF	0.5267	0.4586	0.4717	0.4635
2	0.3134	7	0.5033	0.4381	0.4872	0.4490
3	0.4309	RF	0.4633	0.4053	0.4705	0.4251
2	0.3134	5	0.4700	0.3985	0.4540	0.4109
2	0.3134	3	0.4367	0.3835	0.4288	0.3953
3	0.4309	7	0.4500	0.3710	0.4164	0.3821
4	0.5465	7	0.4733	0.3734	0.4022	0.3819
5	0.6494	3	0.4833	0.3768	0.3772	0.3739
2	0.3134	RF	0.4400	0.3669	0.4023	0.3712
3	0.4309	5	0.4300	0.3561	0.3845	0.3641
4	0.5465	3	0.4400	0.3527	0.3772	0.3565
3	0.4309	3	0.4000	0.3463	0.3752	0.3500
4	0.5465	5	0.4300	0.3431	0.3611	0.3472
5	0.6494	5	0.4300	0.3362	0.3450	0.3381
5	0.6494	7	0.4167	0.3190	0.3271	0.3210

COMPARAÇÃO POR GÊNERO

Comparação da prova final por gênero



Diferença absoluta

- Masculino: 259 estudantes
- Feminino: 256 estudantes


Diferença de apenas 3 estudantes.

Diferença percentual

- Masculino: 50,29%
- Feminino: 49,71%

Diferença de apenas 0,58 ponto percentual.

Impacto do Trabalho em Meio Período na Frequência Escolar por Gênero




Há **17 mulheres** a mais trabalhando em meio período do que homens.

Há apenas **5 homens** a mais que mulheres entre os estudantes que não exercem atividade de meio período

ACESSO A INTERNET POR ESCOLARIDADE

Distribuição de Estudantes segundo Acesso à Internet e Escolaridade

escolaridade_pais ● Bacharelado ● Doutorado ● Ensino Médio ● Mestrado ● NULL




Ensino Médio com mais alunos 256 estudantes, cujos pais possuem Ensino Médio tem acesso à internet.

87,0%


Maior porcentagem dos estudantes tem acesso a internet esta no **Mestrado**

Observa-se que o acesso à internet está presente na grande maioria dos estudantes, independentemente da escolaridade dos pais. Entretanto, estudantes cujos responsáveis possuem níveis mais elevados de escolaridade apresentam proporções ligeiramente superiores de acesso, indicando uma possível relação entre capital educacional familiar e disponibilidade de recursos tecnológicos podendo indicar maior vulnerabilidade ou falta de informações cadastrais.

Soma de frequencia por escolaridade



Desempenho na prava final por escola



RESULTADO

Os resultados obtidos permitiram identificar padrões relevantes no desempenho dos estudantes, destacando a influência de fatores acadêmicos e socioeconômicos. As análises por gênero, frequência escolar e acesso à internet contribuíram para compreender melhor os elementos associados ao sucesso acadêmico. Dessa forma, o modelo desenvolvido demonstra potencial para apoiar decisões educacionais e ações preventivas voltadas à redução da reprovação e melhoria do desempenho dos alunos.

CONCLUSÃO

- ❑ O desenvolvimento do modelo preditivo permitiu identificar fatores relevantes que impactam o desempenho acadêmico dos estudantes, reforçando a importância da análise de dados no contexto educacional.
- ❑ A aplicação de técnicas de Machine Learning demonstrou potencial para classificar estudantes conforme o risco de aprovação ou reprovação, contribuindo para processos de tomada de decisão mais assertivos.
- ❑ Os resultados obtidos evidenciam que variáveis relacionadas aos hábitos de estudo, frequência escolar e condições de vida possuem influência significativa no rendimento acadêmico, possibilitando intervenções pedagógicas mais precoces e eficazes.

“



”

Alunos:

Tainara Almeida, Napoleão Júnior, Júlia Stefany